

Unidade I – LLMs: A Lógica por Trás da IA Generativa

Aula 03 - Compreendendo a mecânica
dos Modelos de Linguagem de
Grande Porte




Professora Kadidja Valéria | Data: 09/03

O que é um Modelo de Linguagem (LLM)?

Não é um banco de dados. Não há arquivos de texto armazenados para consulta direta.

É uma estrutura matricial e condicional gigantesca. Pense como uma "biblioteca abstrata" onde a informação não é acessada buscando em estantes, mas gerada via conversa, completando estímulos através da propagação otimizada de parâmetros (pesos neurais).



A Evolução: De Markov ao Transformer

1913



1913 – Cadeias de Markov

A lógica inicial. Previsão da próxima palavra baseada estritamente na palavra imediatamente anterior.

2017




2017 – O Artigo "Attention Is All You Need"

O marco zero da IA Generativa moderna. A arquitetura **Transformer** introduz o mecanismo de "Atenção", permitindo que o modelo foque em múltiplas partes importantes de um texto longo simultaneamente.

O Coração da Lógica: Tokens

LLMs não leem texto puro. Eles leem **tokens** — códigos numéricos que representam fragmentos de texto separados por frequência estatística.




A Analogia Morfológica

O modelo "aprende" fragmentos como estudamos gramática:

- **cas-** (radical remetendo a casa)
- **-a-** (vogal temática)
- **-inha** (sufixo de diminutivo)

O Processo de Geração (Visão Geral)

A transformação de uma pergunta em resposta ocorre em um fluxo sequencial contínuo de decodificação matemática.




Mergulho na Arquitetura: Embedding e Atenção

Embedding

Transforma cada token (número) em um vetor complexo, mapeando seu significado em um espaço multidimensional.

Multi-head Self-Attention


O modelo calcula "scores de atenção", medindo a relevância de cada token anterior na frase para prever com exatidão o próximo token.



A Magia da Probabilidade: Softmax

Após cruzar bilhões de parâmetros, a rede gera valores brutos (**logits**). A função matemática **Softmax** converte esses valores em uma lista de distribuição de probabilidades (de 0 a 100%).

O modelo ranqueia o vocabulário inteiro para decidir qual é o fragmento estatisticamente perfeito para continuar a frase.



comer	54.6%
dormir	20.8%
correr	6.2%


O "Volante" da Criatividade: Temperatura

A Temperatura altera a curva da probabilidade gerada pelo Softmax antes da escolha final.

Temperatura < 1: Achata as opções. O modelo fica técnico, previsível e analítico.


Temperatura > 1: Amplia as opções. O modelo assume riscos, escolhendo palavras menos prováveis, gerando textos criativos (e às vezes alucinações).

Temperatura




Refinando a Seleção: Top-k e Top-p

Top-k Sampling: Considera apenas os k tokens com as maiores probabilidades absolutas, descartando sumariamente opções menos prováveis.



Top-p Sampling: Seleciona um conjunto dinâmico de tokens cuja soma de probabilidade ultrapassa um limiar p (ex: 0.9). Garante diversidade controlada.




Estruturando o Pensamento: Chain-of-Thought (CoT)

Como o modelo prevê um token de cada vez, forçar a IA a gerar etapas intermediárias dá a ela "tempo de computação" para chegar à resposta correta.

O Desafio Lógico

"Qual é a terceira letra da quinta palavra da frase 'O rato roeu a roupa do Rei de Roma'?"


***Solução CoT*:** Adicionar a restrição ""Resolva passo a passo: 1. Identifique as palavras; 2. Conte até a quinta..." previne alucinações.



O Futuro da Arquitetura: Mixture of Experts (MoE)

A arquitetura avançada usada em modelos como DeepSeek e Mixtral. Em vez de ativar toda a rede para cada palavra, o modelo divide sua capacidade.

Um roteador decide **dinamicamente** qual "Especialista" ativar (ex: visão, linguagem ou lógica). Isso garante escalabilidade gigante sem aumento proporcional no custo computacional.



Atividade Prática: Desmontando a Máquina



(35 min total)

Etapa 1 – Análise de Tokens (15 min):

Acesse o *OpenAI Tokenizer*. Insira seu nome completo e a frase: **"A engenharia de prompt otimiza LLMs"**. Registre quantos tokens foram gerados e observe a divisão morfológica.

Etapa 2 – Teste de Previsibilidade (20 min):

No ChatGPT ou Gemini, envie o prompt: **"O gato come..."**. Peça para listar as 3 palavras mais prováveis com justificativas lógicas. Simule diferentes temperaturas pedindo para a IA ser "muito criativa" vs "muito técnica".

Atividade Prática: Desbloqueando o Raciocínio



Etapa 3 – Raciocínio CoT (25 min):

Teste o desafio: “Qual é a terceira letra da quinta palavra da frase ‘O rato roeu a roupa do Rei de Roma?’” Se a IA errar, refaça o prompt forçando o passo a passo (Chain-of-Thought).

Entrega (GitHub):

Crie um arquivo **aula03.md** no repositório da disciplina. Insira os *prints* das Etapas 1 e 3. Escreva uma breve conclusão refletindo sobre como a divisão de tokens influencia diretamente a resposta da IA.

Referências Bibliográficas

LARGUESA, Ricardo Pupo. **Engenharia de prompt para DEVs**: um guia para aprender a usar a IA antes que a IA aprenda a usar você. 2. ed. São Paulo: Casa do Código, 2025.

WEI, Jason et al. **Chain-of-Thought Prompting Elicits Reasoning in Large Language Models**. Google Research, 2022.

VASWANI, Ashish et al. **Attention Is All You Need**. 2017. Disponível em: arxiv.org/pdf/1706.03762.pdf.